

Documentacao dos modelos e das estatisticas

Atualizado em 05/06/2026. Este documento explica, em linguagem tecnica mas operacional, como os modelos do experimento funcionam, como interpretar as metricas e quais criterios estatisticos serao usados antes de qualquer validacao humana.

1. Base usada pelos modelos

Cada chamado e transformado em um texto unico a partir de quatro campos da aba CHAMADOS_ESQUELETO_REDUIDO:

Campo	Coluna	Uso
Título GLPI	B	resumo curto do problema
Descricao GLPI	D	texto principal do chamado
Título O.S.M.	E	titulo operacional complementar
Descricao O.S.M.	F	descricao operacional complementar

Exemplo como se fosse Google Sheets:

```
=B2 & " " & D2 & " " & E2 & " " & F2
```

Esse texto combinado e a entrada dos modelos. A categoria historica em C e usada como rotulo de treino/comparacao. Enquanto validados=0, todas as metricas sao contra esse historico, nao contra verdade humana validada.

2. Pipeline geral

```
flowchart LR
A["Texto do chamado\nB + D + E + F"] --> B["Pre-processamento"]
B --> C["Modelo de IA"]
C --> D["Categoria prevista"]
C --> E["Confianca"]
D --> F["Compara com categoria historica"]
E --> G["Faixa: <70, 70-95, >=95"]
F --> H["Metricas e dashboard"]
G --> H
```

3. TF-IDF: como o texto vira numeros

Modelos classicos nao leem texto diretamente. Primeiro o texto vira uma tabela numerica por termo.

Exemplo simplificado:

Chamado	ar condicionado	vazamento	eletrica
1	0.80	0.10	0.00
2	0.00	0.70	0.20
3	0.10	0.00	0.90

Como uma celula de planilha, a ideia e:

```
TF_IDF(termo, chamado) = frequencia_do_termo_no_chamado * raridade_do_termo_na_base
```

Termos muito frequentes em muitos chamados pesam menos; termos mais caracteristicos pesam mais.

4. Naive Bayes

O Naive Bayes estima a probabilidade de uma categoria dado o conjunto de palavras.

Equacao:

```
P(categoria | palavras) proporcional a P(categoria) * produto(P(palavra | categoria))
```

Em linguagem de planilha:

```
=prob_categoria * prob_palavra1_na_categoria * prob_palavra2_na_categoria * ...
```

Uso: rapido, simples, bom como baseline. Limite: assume independencia entre palavras, o que raramente e totalmente verdadeiro.

5. Regressao Logistica

A regressao logistica soma pesos das palavras para cada categoria e transforma isso em probabilidade.

Equacao simplificada:

```
score = peso_1*termo_1 + peso_2*termo_2 + ... + bias  
probabilidade = 1 / (1 + exp(-score))
```

Como planilha:

```
=1/(1+EXP(-(A2*B2 + A3*B3 + A4*B4 + bias)))
```

Uso: forte para texto com TF-IDF, interpretavel por pesos. No experimento, esta entre os modelos competitivos.

6. Linear SVC

O Linear SVC separa categorias por margens. Ele tenta achar uma fronteira que deixe exemplos de categorias diferentes o mais separados possivel.

Equacao:

```
score_categoria = soma(peso_termo * valor_tfidf)  
categoria = maior score
```

Como planilha:

```
=SE(score_categoria_A > score_categoria_B; "Categoria A"; "Categoria B")
```

Uso: muito forte para classificacao de texto. No multimodelo atual, foi o melhor contra o historico: 80, 26% de concordancia acumulada.

7. SGD

O SGD e uma forma de treinar modelo linear em passos pequenos. Ele atualiza pesos aos poucos, olhando exemplos e corrigindo erros.

Ideia operacional:

```
peso_novo = peso_antigo - taxa_aprendizado * erro
```

Como planilha conceitual:

```
=peso_antigo - (taxa * erro)
```

Uso: bom para bases grandes e treino incremental. Resultado atual ficou proximo dos outros lineares.

8. Random Forest e Extra Trees

Sao conjuntos de arvores de decisao. Cada arvore vota em uma categoria.

Exemplo:

Arvore	Voto
1	Manutencao eletrica
2	Manutencao eletrica
3	Climatizacao

Resultado:

```
categoria = voto majoritario
```

Como planilha:

```
=MODA(voto_arvore_1:voto_arvore_200)
```

Extra Trees usa divisoes mais aleatorias, aumentando diversidade. Random Forest escolhe divisoes buscando melhor separacao.

9. LSTM bidirecional

O LSTM e uma rede neural recorrente. Ele le a sequencia de tokens e tenta capturar contexto.

```
flowchart LR
A["tokens do chamado"] --> B["embedding"]
B --> C["LSTM esquerda -> direita"]
B --> D["LSTM direita -> esquerda"]
C --> E["vetor combinado"]
D --> E
E --> F["camada densa"]
F --> G["softmax por categoria"]
```

Configuracao registrada:

Perfil	Vocabulario	Sequencia	Embedding	Observacao
padrao	8.000	120 tokens	128	rapido, usado em Etapa 1
robusto	20.000	220 tokens	192	maior, mais lento

Softmax:

```
prob_categoria_i = exp(score_i) / soma(exp(score_de_todas_as_categorias))
```

Como planilha:

```
=EXP(score_categoria)/SOMA(EXP(score_todas_as_categorias))
```

Leitura atual: apesar de ser mais sofisticado, o LSTM materializado ficou abaixo dos modelos lineares contra o historico. No multimodelo atual: 67, 57%, enquanto linear_svc chegou a 80, 26%.

10. Comparacao atual das 7 IAs

Resultado da materializacao out-of-fold, sem vazamento:

Modelo	Registros	Pendentes	Concordancia vs historico
linear_svc	13.825	0	80,26%
extra_trees	13.825	0	78,47%
sgd	13.825	0	77,51%
random_forest	13.825	0	76,80%
regressao_logistica	13.825	0	76,59%
naive_bayes	13.825	0	70,07%
lstm	13.825	0	67,57%

Critério: a melhor IA atual contra historico e linear_svc. Isso nao significa aprovacao final, porque a categoria historica pode conter erros.

11. Estatisticas: para que servem

As estatisticas entram para responder perguntas que graficos simples nao respondem.

Pergunta	Teste/indicador
A confianca alta realmente acompanha acerto?	correlacao confianca x acerto
Os modelos sao significativamente diferentes?	Cochran Q, McNemar, Friedman
A evolucao por turno tem tendencia?	regressao linear, residuos, Durbin-Watson
As metricas por turno seguem normalidade?	Shapiro-Wilk
Qual incerteza da acuracia?	bootstrap IC 95%
As IAs concordam entre si?	Fleiss Kappa
A IA concorda com o historico?	Cohen Kappa

12. Criterios estatisticos

Correlacao confianca x acerto

Uso: verificar se a confianca do modelo e confiavel.

Leitura:

```
r perto de 0: confianca nao explica acerto  
r positivo alto: confianca alta tende a acertar mais  
p < 0,05: relacao estatisticamente detectavel
```

Shapiro-Wilk

Uso: testar se a distribuicao da concordancia por turno parece normal.

Criterio:

```
p > 0,05: nao rejeita normalidade  
p <= 0,05: distribuicao nao normal
```

Se nao for normal, preferir testes nao-parametricos.

Residuos e Durbin-Watson

Uso: verificar se a evolucao por turno tem padroes suspeitos.

Durbin-Watson:

perto de 2: residuos independentes
perto de 0: autocorrelacao positiva
perto de 4: autocorrelacao negativa

Cochran Q

Uso: comparar varios classificadores nas mesmas linhas.

Criterio:

$p < 0,05$: pelo menos uma IA difere das outras em acuracia

McNemar

Uso: comparar dois modelos linha a linha.

Exemplo:

	Modelo B acerta	Modelo B erra
Modelo A acerta	ambos acertam	so A acerta
Modelo A erra	so B acerta	ambos erram

Criterio:

$p < 0,05$: diferenca entre os dois modelos e significativa

Friedman + Nemenyi

Uso: comparar rankings de modelos em varios recortes.

Criterio:

Friedman $p < 0,05$: ha diferenca global entre modelos
diferenca de rank medio $> CD$: diferenca significativa no pos-teste Nemenyi

Kappa

Uso: medir concordancia descontando acaso.

Leitura pratica:

Kappa	Interpretacao
<0,20	fraca
0,21-0,40	baixa
0,41-0,60	moderada
0,61-0,80	substancial
>0,80	quase perfeita

13. Decisao antes da validacao humana

1. Nao iniciar validacao humana ainda.

2. Finalizar visualizacao estatistica no dashboard.
3. Usar multimodelo como fonte comparativa principal.
4. Tratar `linear_svc` como candidato mais forte atual.
5. Reclassificacao fica sem prioridade ate concluir a Etapa 1/multimodelo e estatistica.
6. So depois iniciar validacao humana para confirmar se o historico ou a IA esta correta.