

Estado do Roteiro Metodológico (50 etapas) + atualizações

Avaliação de onde o experimento está em relação ao ****Roteiro Metodológico para Avaliação da Evolução da Classificação e Reclassificação Automática de Chamados no Malha IA (50 etapas), atualizada**** com as decisões dos últimos dias.

Legenda: ■ feito · ■ parcial/pronto-não-executado · ■ pendente · ■■ pausado por decisão do usuário.

Atualizado: 2026-06-05 (America/Bahia). Base observada: ~13.825 chamados elegíveis (cresce).

Etapa 1 — Classificação inicial (etapas 1–16)

#	Etapa	Estado	Evidência
1	Isolamento do ambiente	■	repo classificacao-chamados + aba CHAMADOS_ESQUELETO_REDUZIDO, separados do Malha IA
2	Base inicial congelada	■	~13.825 elegíveis (categoria C + texto); recontada por execução (dados dinâmicos)
3	Limpeza dos resultados anteriores	■	resetar_experimento.py limpa G:K (preserva C, L, M)
4	Fórmula de conferência IA×original	■	$K = SE(G=""; "" ; G=C)$ (no layout reduzido o original é C, não M)
5	run_id único	■	EXP_CLASSIFICACAO_CHAMADOS_2026_06_001
6	Registro da configuração	■	config_experimento.json + aba EXPERIMENTO_CONFIG
7	Aba EXPERIMENTO_CONFIG	■	criada
8	Aba LOG_TURNOS_CLASSIFICACAO	■	turnos de 15, taxa + acumulada
9	Aba LOG_LINHA_A_LINHA	■	criada
10	Execução Etapa 1 em turnos de 15	■	executar_etapa1.py (LSTM+RF) progressivo
11	Registro imediato por turno	■	append por turno
12	Concordância por turno	■	gráfico no painel
13	Concordância acumulada	■	gráfico no painel
14	Análise de confiança por faixa	■	faixas <70 / 70–95 / ≥95
15	Análise por executor/método	■→estendida	LSTM/RF na Etapa 1; ampliada para 7 IAs (ver Extensão A)
16	Congelamento da Etapa 1	■	SNAPSHOT_ETAPA_1

Etapa 2 — Reclassificação (etapas 17–23)

#	Etapa	Estado	Evidência
17	Candidatos < 95%	■	executar_etapa2.py + reclassificacao_multimodelo.py
18	Aba LOG_TURNOS_RECLASSIFICACAO	■	criada
19	Estado anterior à reclassificação	■	lido do snapshot
20	Execução da Etapa 2	■	scripts prontos; dry-run validado; não aplicada após o reset
21	Estado posterior	■	estrutura pronta (antes/depois)
22	Ganho líquido	■	calculado (corrigidos – prejudicados)
23	Comparação etapa1×etapa2 vs original	■	depende de rodar a Etapa 2

Validação humana (etapas 24–35) — ■■ PAUSADA por decisão do usuário

#	Etapa	Estado
24	Preparação da validação humana	■ (aba VALIDACAO_HUMANA com 1.654 casos divergentes + dropdowns)
25–33	Validação divergentes/todos; IA_CERTA/GLPI_CERTO/AMBOS_ERRADOS/AMBOS_CORRETOS/CASO_AMBIGUO/NAO_AVALIADO	■■ não iniciar agora (fortalecer modelo/scripts antes)
34	Campo "usar para treino" (SIM/NAO/REVISAR)	■ estrutura pronta (memoria_validada.py)
35	Versão da taxonomia	■

Métricas e comparações (etapas 36–43)

#	Etapa	Estado	Observação
36	Matriz de confusão	■	definitiva precisa de validação humana; dá para gerar vs histórico já
37	Métricas por categoria	■	METRICAS_POR_CATEGORIA (vs histórico)
38	Confiança × acerto (calibração)	■	calibracao.json (ECE); definitiva após validação . OOF tornou honesta
39	Avaliação real da reclassificação	■	precisa de validação humana
40	Comparação histórico/etapa1/etapa2	■	
41	Base validada para retreino	■	memoria_validada pronto, sem dados ainda
42	Modelo treinado em histórico × validado	■	
43	Indicadores consolidados	■	parte no painel

Gráficos e diagnóstico (etapas 44–45)

#	Etapa	Estado
44	Gráficos de evolução por turno	■ (painel: concordância/turno, acumulada, confiança/turno, faixas, evolução por IA)
45	Análise dos erros mais relevantes	■ (categorias de menor concordância no painel; falta o resto)

Taxonomia, governança e síntese (etapas 46–50)

#	Etapa	Estado
46	Revisão da taxonomia	■
47	Regras de revisão humana contínua	■
48	Matriz de evidências	■
49	Síntese metodológica	■ (CONTEXTO.md)
50	Apresentação ao orientador	■

Atualizações solicitadas nos últimos dias (além do roteiro)

Extensão A — Comparação MULTIMODELO das 7 IAs (out-of-fold)

Amplia a Etapa 15 (análise por executor/método) de LSTM/RF para **7 algoritmos**:

naive_bayes, regressao_logistica, linear_svc, sgd, extra_trees, random_forest, lstm.

- **Cada IA classifica TODA a base** na sua própria aba CLASSIF__<modelo>, com sua confiança, faixa, executor, calibração e reclassificação próprias.

- **Out-of-fold (sem vazamento)**: a IA que rotula a linha *i* nunca treinou na linha *i* (k-fold na materialização; top-up incremental depois). Essencial para a calibração honesta da Etapa 38 (critério dos $\geq 95\%$).

- **Lote dinâmico**: processa o que estiver pendente, mesmo < lote, até 1 chamado.

- **Estado**: ■ 6 modelos leves materializados (13.825 cada, 0 pendentes, kfold_5); concordância vs histórico: linear_svc 80,3% > extra_trees 78,5% > sgd 77,5% > random_forest 76,8% > regressao_logistica 76,6% > naive_bayes 70,1%.

- **LSTM** em materialização (7ª IA, para comparar TODOS juntos).

- **Painel**: aba **Multimodelo** com tabela de progresso + curva de evolução por IA.

Extensão B — ANÁLISES ESTATÍSTICAS (a adicionar) ■

Além das métricas já previstas (concordância, F1, calibração/ECE, ganho líquido), incorporar análise estatística formal aos resultados:

- **Correlação**: entre confiança e acerto; entre nº de chamados por categoria e concordância; entre comprimento/qualidade do texto e acerto (Pearson/Spearman).

- **Normalidade**: testar distribuição das métricas/erros (Shapiro–Wilk, D'Agostino, Kolmogorov–Smirnov; QQ-plots) para escolher testes paramétricos vs não-paramétricos.

- **Análise de resíduos**: resíduos de concordância por turno/categoria; homocedasticidade, autocorrelação (Durbin–Watson), tendência ao longo dos turnos.

- **Testes de significância entre modelos**: comparar as 7 IAs (McNemar par a par para classificadores; Cochran's Q / Friedman + pós-teste de Nemenyi entre os 7; intervalos de confiança por bootstrap da acurácia/F1).

- **Concordância entre avaliadores/fontes**: Kappa de Cohen (IA × histórico; IA × validação humana quando existir) e Kappa de Fleiss entre as IAs.

- **Tamanho de efeito e IC**: bootstrap dos indicadores (acurácia, F1, ECE) com IC 95%.

- **Saída**: tabelas/figuras publicáveis (ABNT) + JSON agregado p/ o painel (sem texto).

Atualizações no PAINEL (feitas)

- Filtros: chips dos ativos, botões destacados, Limpar com contagem; **aparecem só nas abas onde funcionam** (Classificacao/Categorias/Metricas) e somem nas demais.

- ■■ Na aba **Classificacao**, o filtro **Executor** só mostra LSTM/LSTM_BAIXA_CONF porque o registros.json vem do SNAPSHOT_ETAPA_1 (Etapa 1 = só LSTM). A comparação das 7 IAs está na aba **Multimodelo** (e na aba **Modelos**). Para filtrar por IA na

própria Classificação seria preciso publicar registros por modelo (decisão futura).

- Aba **Modelos**: média + ranking + evolução por lote (todos os recortes).
- Overflow horizontal corrigido.

Próximo do roteiro: concluir o LSTM (Ext. A) → rodar Etapa 2 multimodelo → implementar a Extensão B (estatística) → quando liberado, validação humana (24–35) e métricas validadas (28, 36, 38–43).